Lab08 - Mazo

Gustavo Mazo Vieira

```
reticulate::py_install("polars")
```

```
Using virtual environment "\\smb/ra187263/Documentos/.virtualenvs/r-reticulate" ...

+ "\\smb/ra187263/Documentos/.virtualenvs/r-reticulate/Scripts/python.exe" -
m pip install --upgrade --no-user polars
```

```
import polars as pl

pasta = r"\\smb\ra187263\Downloads"

basics = pl.scan_csv(
    pasta + r"\title.basics0.tsv.gz",
    separator="\t",
    null_values=r"\N"
)

principals = pl.scan_csv(
    pasta + r"\title.principals0.tsv.gz",
    separator="\t",
    null_values=r"\N"
)

ratings = pl.scan_csv(
    pasta + r"\title.ratings.tsv.gz",
    separator="\t",
    null_values=r"\N"
)
```

1) Quais são os 5 filmes com as maiores notas (averageRating)? Apresente uma solução capaz de desempatar os filmes baseando-se no número de votos recebidos.

```python
top_5_filmes = (
    basics
    .filter(pl.col("titleType") == "movie")
    .join(ratings, on="tconst", how="inner")
    .select(
        "tconst",
        "primaryTitle",
        "startYear",
        "averageRating",
        "numVotes"
    )
    .sort(
        ["averageRating", "numVotes"],
        descending=[True, True]
    )
    .head(5)
)

print(top_5_filmes.collect())
```

```
shape: (5, 5)

 tconst      primaryTitle               startYear  averageRating  numVotes
 ---         ---                        ---        ---            ---
 str         str                        i64        f64            i64

 tt33075815  Kaveri                     2024       10.0           1023
 tt27815015  Kurukku                    2024       10.0           451
 tt28450376  Jedal Dar Omghe 30 Metri   2009       10.0           142
 tt27859713  Sargashte                  2016       10.0           134
 tt33507675  Gorgeous Rascal            2024       10.0           115
```

2) Qual é o gênero mais frequente entre os filmes com nota maior que 8?

```python
genero_mais_frequente = (
    basics
    .filter(pl.col("titleType") == "movie")
    .join(ratings, on="tconst", how="inner")
    .filter(pl.col("averageRating") > 8)
    .filter(pl.col("genres").is_not_null())
    .with_columns(
```

```
        pl.col("genres").str.split(",")
    )
    .explode("genres")
    .filter(pl.col("genres") != "\\N")
    .group_by("genres")
    .agg(
        pl.len().alias("quantidade_filmes")
    )
    .sort(
        "quantidade_filmes",
        descending=True
    )
    .head(1)
    .collect()
)

print(genero_mais_frequente)
```

```
shape: (1, 2)

 genres        quantidade_filmes
 ---           ---
 str           u32

 Documentary   10564
```

3) Quais são os 3 atores/atrizes que mais participaram de filmes com nota maior que 7.5?

```
top3_atores = (
    basics
    .filter(pl.col("titleType") == "movie")
    .select("tconst")
    .join(ratings, on="tconst", how="inner")
    .filter(pl.col("averageRating") > 7.5)
    .select("tconst")
    .join(principals, on="tconst", how="inner")
    .filter(
        pl.col("category").is_in(["actor", "actress"])
    )
    .group_by("nconst")
    .agg(
```

```
        pl.col("tconst").n_unique().alias("quantidade_filmes")
    )
    .sort(
        ["quantidade_filmes", "nconst"],
        descending=[True, False]
    )
    .head(3)
    .collect()
)

print(top3_atores)
```

```
shape: (3, 2)

 nconst      quantidade_filmes
 ---         ---
 str         u32

 nm0004660   199
 nm0595934   155
 nm3183374   124
```

```
Sys.setenv(TZ = "America/Sao_Paulo")
Sys.time()
```

```
[1] "2026-10-14 18:35:06 -03"
```