Lab09_Mazo

Gustavo Mazo Vieira

1)

```
from plotnine import *
from plotnine.data import diamonds
import pandas as pd

print(diamonds.head())
```

```
   carat      cut color clarity  depth  table  price     x     y     z
0   0.23    Ideal     E     SI2   61.5   55.0    326  3.95  3.98  2.43
1   0.21  Premium     E     SI1   59.8   61.0    326  3.89  3.84  2.31
2   0.23     Good     E     VS1   56.9   65.0    327  4.05  4.07  2.31
3   0.29  Premium     I     VS2   62.4   58.0    334  4.20  4.23  2.63
4   0.31     Good     J     SI2   63.3   58.0    335  4.34  4.35  2.75
```

```
print(diamonds.shape)
```

```
(53940, 10)
```

```
print(diamonds.info())
```

```
<class 'pandas.DataFrame'>
RangeIndex: 53940 entries, 0 to 53939
Data columns (total 10 columns):
 #   Column   Non-Null Count  Dtype
---  ------   --------------  -----
 0   carat    53940 non-null  float64
 1   cut      53940 non-null  category
 2   color    53940 non-null  category
 3   clarity  53940 non-null  category
```

```
 4   depth    53940 non-null  float64
 5   table    53940 non-null  float64
 6   price    53940 non-null  int64
 7   x        53940 non-null  float64
 8   y        53940 non-null  float64
 9   z        53940 non-null  float64
dtypes: category(3), float64(6), int64(1)
memory usage: 3.0 MB
None
```

2)

```
quest2 = (
    ggplot(diamonds, aes(x="carat", y="price")) +
      geom_point(
        alpha=0.2,
        size=0.7,
        color="steelblue"
    ) +
    labs(
        title="Carat x Price",
        x="Carat",
        y="Price",
    )
    + theme_minimal()
)

print(quest2)
```

```
<ggplot: (640 x 480)>
```

Resposta da 2: O gráfico 'quest2' nos demonstra que, de maneira geral, Price e Carat se associam de maneira positiva (quanto maior Carat, maior Price). Entre- tanto, apesar dessa relação entre Carat e Price, a imensa variação de preço dado um mesmo peso indica que o Carat não é o único fator que afeta o valor final de Price e que o gráfico sugere que a relação entre ambas não deve ser uma relação linear. Para melhorar a qualidade da visualização, foram utilizados pontos pequenos e semitransparentes, reduzindo a sobreposição das observações, além do título, rótulos dos eixos e um tema minimalista.

3)

```
quest3 = (ggplot(diamonds, aes(x="carat", y="price")) +
      geom_point(
        alpha=0.2,
        size=0.7,
        color="steelblue"
    ) +
      facet_wrap("~cut", ncol=3) +
      labs(
        title="Carat x Price por Cut",
        x="Carat",
        y="Price"
    ) +
    theme_minimal()
)

print(quest3)
```

```
<ggplot: (640 x 480)>
```

Resposta da 3: O gráfico "quest3" revela que, em todas as categorias de corte, Price e Carat se associam de maneira positiva (como foi mostrado na questão 2). Assim como observado na análise anterior, a relação parece ser não linear, pois os preços tendem a aumentar de forma mais acentuada para diamantes de maior peso. Entretanto, existem diferenças na distribuição e na dispersão de Price entre as categorias de Cut, indicando que o comportamento dos preços não é exatamente igual para todos os cortes. Além disso, há uma variação considerável nos preços de diamantes com valores de Carat semelhantes dentro de cada grupo. Portanto, embora a tendência geral seja semelhante entre as categorias, a relação entre peso e preço apresenta diferenças conforme a qualidade do corte. Exemplo: Note que para Carat = 2, o grupo Premium apresenta um preço médio superior ao grupo Fair.

4)

```
quest4 = (ggplot(diamonds,aes(x="carat", y="price", color="color")
    ) +
    geom_point(
        alpha=0.2,
        size=0.7
    ) +
    facet_grid("cut ~ clarity") +
    labs(
        title="Carat x Price por Cut, Color e Clarity",
```

```
        x="Peso (quilates)",
        y="Preço (USD)",
        color="Color"
    ) + theme_minimal())

print(quest4)
```

```
<ggplot: (640 x 480)>
```

Resposta da 4: A principal dificuldade encontrada foi representar um grande número de observações e classificações diferentes sem comprometer a legibilidade. Para contornar esse problema, foram utilizados painéis separados por Cut e Clarity, enquanto as cores dos pontos representam Color. Sobre cada combinação possível, podemos observar que a dispersão e a quantidade de observações variam entre os grupos, sendo algumas combinações muito menos representadas do que outras. As diferenças entre cada grupo nos fazem confirmar a nossa sugestão feita na questão 2 (que Carat não é o único fator que afeta o valor final de Price).

```
Sys.setenv(TZ = "America/Sao_Paulo")
Sys.time()
```

```
[1] "2026-10-20 21:53:31 -03"
```